


AI 서비스기술분석



Openclaw-RL

대화만으로 모든 에이전트를 학습시키기


github.com/Gen-Verse/OpenClaw-RL

arxiv.org/abs/2603.10165

20263804 김지우

Nvidia GTC 2026

젠슨황 CEO



오픈클로(OpenClaw)는 인류 역사상 가장 인기 있는 오픈 소스 프로젝트입니다.

리눅스(Linux)가 지난 30년 동안 이룩한 생태계를, 오픈클로는 불과 몇 주 만에 넘어섰습니다.

Openclaw


피터 슈타인베르거



- Clawdbot : 첫 공개. 엔트로픽의 상표권 경고로 명칭 변경.
- Moltbot : 탈피(Molting)를 의미했으나 초기 보안 이슈 연루.
- OpenClaw : 최종 명칭 확정. 리눅스의 30년 생 태계를 단 몇 주 만에 초월.

Openclaw


행동하는 AI 에이전트




- 실제 행동 수행
- 자동화된 워크플로우
- 자율적 문제 해결
- 자체 호스팅
- 메신저 연동
- 다양한 모델 활용
- 오픈소스

기존 업무 과정 & 오픈클로

기존의 순차적 작업




오픈클로의 자율성



강력한 자율성의 그림자 : 보안 위험

막강한 자율 실행 권한은 기업에게 거대한 보안 리스크로 작용.

메타(META)에서는 테스트 중이던 에이전트가 이메일을 무단 삭제하거나 방대한 사내 정보를 노출시키는 사고가 발생.



서머 유

OPENCLAW에게 "작업 전에 확인"이라고 말하고는 순식간에 받은 편지함을 삭제하는 모습을 지켜보는 것만큼 겸손해지는 경험은 없을 겁니다.

휴대폰으로는 막을 수가 없었어요.
마치 폭탄을 해체하듯 맥 미니로 달려가야 했습니다.

해결책 : NemoClaw



엔비디아가 제시한 해답은 기업용 플랫폼 네모클로(NemoClaw).


'오픈클로의 강력한 자율성은 유지하되, 오픈셸(OpenShell)'이라는 안전한 샌드박스(격리 환경)를 도입해 기밀 유출 없이 AI를 통제.

외부 클라우드가 아닌 사내 구축형 장비인 'DGX 스테이션'과 결합하여, 기밀 데이터 유출 없이 AI 직원을 안전하게 고용할 수 있는 엔터프라이즈의 표준을 제시.

본질적 질문 : 매일 버려지는 데이터

기존 AI는 피드백을 창을 닫으면 잊는다.


이를 고치려면 수만 건의 데이터를 모아 막대한 비용을 들여 오프라인 서버에서 재학습시켜야 한다.



OpenClaw-RL의 접근

사용자의 피드백, 터미널 에러 로그 같은 '다음 상태 신호'를 일회성으로 버리지 않고, 100% 실시간 온라인 학습 자원으로 재활용.

1. 이진 강화학습 (Binary RL), 다수결 투표



- next-state signal $\rightarrow$ +1 / -1 reward로 변환
- PRM이 판단해서 reward 생성
- 평가 신호만 사용 (evaluative signal)
- 가장 기본적인 RL 방식

4.1.1. PRM Judge Construction via Majority Vote

Given response a_t and next state s_{t+1} , a judge model evaluates quality of a_t :

$$\text{PRM}(a_t, s_{t+1}) \rightarrow r \in \{+1, -1, 0\}.$$

4.1.2. RL Training Objective

By directly using the advantage $A_t = r_{\text{final}}$, the training objective is a standard PPO-style clipped surrogate with asymmetric bounds (Schulman et al., 2017):

$$\rho_t = \frac{\pi_\theta(a_t | s_t)}{\pi_{\text{old}}(a_t | s_t)}, \quad \mathcal{L}_{\text{pg}} = -\mathbb{E}_t \left[\min(\rho_t A_t, \text{clip}(\rho_t, 1 - \epsilon, 1 + \epsilon_{\text{high}}) \cdot A_t) \right], \quad \mathcal{L} = \mathcal{L}_{\text{pg}} + \beta_{\text{KL}} \cdot \mathcal{L}_{\text{KL}}, \quad (1)$$

where $\epsilon = 0.2$, $\epsilon_{\text{high}} = 0.28$, $\beta_{\text{KL}} = 0.02$. Note that this is a real-time conversational setting, so there is no group structure available for standardization as in GRPO (Shao et al., 2024).

내용 요약: 즉각적인 평가적 신호

사용자의 재질문, 코드 에러 시 여러 개의 과정 보상 모델(PRM)이 이를 감지하여 다수결로 최종 reward 결정

2. 사후 판단 기반 온폴리시 증류 (OPD)

4.2. Hindsight-Guided On-Policy Distillation (OPD) for Personal Agent

Converting directional next-state signals into token-level teacher supervision.

4.2.1. Why Token-Level Supervision from Next-State Signals?

Binary RL reduces the entire information content of s_{t+1} to a single scalar $r \in \{+1, -1, 0\}$. Yet a user who writes “you should have checked the file before editing it” communicates far more: not just that the response was wrong, but *which tokens* should have been different and *how*. This directive information is lost entirely by scalar rewards.

4.2.2. Token-Level OPD

Step 1. Hindsight hint extraction.

$$\text{Judge}(a_t, s_{t+1}) \rightarrow \{\text{score} \in \{+1, -1\}, \text{hint} \in \mathcal{T}^*\}.$$

Step 2. Hint selection and quality filtering.

Step 3. Enhanced teacher construction.

Step 4. Token-level advantage. The policy model is queried under s_{enhanced} with the *original* response a_t as forced input, computing log-probabilities for each response token. Then we have the token-level advantage in on-policy distillation:

$$A_t = \log \pi_{\text{teacher}}(a_t \mid s_{\text{enhanced}}) - \log \pi_{\theta}(a_t \mid s_t).$$

Step 1: hint 추출

- next-state $\rightarrow$ "어떻게 고쳐야 하는지"

Step 2: 품질 필터링

- hint 포함해서 다시 답 생성

Step 3: 강화된 교사 문맥 구성

- 강화된 프롬프트 생성

Step 4: 토큰 수준의 이점 계산

- 정밀한 방향성을 결정

내용 요약: 지시적 신호(텍스트 힌트)를 추출

기존 RL:

- “틀렸다”

OPD:

- “어디가 틀렸고 어떻게 고쳐야 한다”

3. 실험 : 단 몇 번의 대화로 학습

모델 맞춤화 점수 : 0.17 → 0.76 → 0.81

	Updated 8 steps	Updated 16 steps
Binary RL	0.25	0.23
OPD	0.25	0.72
Combined	0.76	0.81

학생 시나리오

목표: AI를 쓴 티를 내지 않고 숙제하기

Before

"1. 신발은 \$80
2. 3 곱하기 \$80 = \$240
최종 정답: \$220"
(기계적이고 AI 특유의 번호 매기기)

After (단 36번의 대화 후)

"가방은 \$220야. 풀이는 이래: 신발이 \$80니까 3배하면 \$240이고, 거기서 \$20를 빼면 \$220이 돼."
(자연스러운 일상 언어 문체로 완벽히 전환)

교사 시나리오

목표: 학생에게 친절하고 구체적인 피드백 주기

Before

"정답: 30. 당신의 풀이는 맞았습니다.
차지한 공간: 90.
남은 공간: 30."
(딱딱하고 건조한 'cold' 피드백)


After (단 24번의 피드백 후)

"120에서 90을 잘 찾아냈네요! 아주 작은 오차가 있는데, 'units'는 소문자로 써야 합니다! 정말 잘했어요! 😊"
(다정하고 구체적인 맞춤형 튜터로 진화)

시스템 아키텍처 (비동기 + 무중단 루프)

- Policy Serving (응답 생성)
- Environment (사용자/환경)
- PRM Judge (평가)
- Training (학습)

시스템은 4개의 독립된 비동기 루프(SGLang, PRM 서버, Megatron 등)로 완전히 분리되어 작동.



Policy Serving (SGLang) → environment (Http / API) → Reward Judging (SGLang / API) → Policy Training (Megatron)

내용 요약 : 비동기 시스템 위에서 Binary RL + OPD를 결합해서 대화만으로 학습하는 구조

개념	역할
Binary RL	잘했는지 판단
Majority Vote	판단 안정화
OPD	어떻게 고칠지 학
Student/Teacher	personalizatio
Async 구조	실시간 학습 가능

OpenClaw-RL: Train Any Agent Simply by Talking

Yinjie Wang*, Xuyang Chen*, Xiaolong Jin*, Mengdi Wang†, Ling Yang†

<https://github.com/Gen-Verse/OpenClaw-RL>

Every agent interaction generates a **next-state signal**, namely the user reply, tool output, terminal or GUI state change that follows each action, yet no existing agentic RL system recovers it as a live, online learning source. We present **OpenClaw-RL**, a framework built on a simple observation: next-state signals are universal, and policy can learn from all of them simultaneously. Personal conversations, terminal executions, GUI interactions, SWE tasks, and tool-call traces are not separate training problems. They are all interactions that can be used to train the same policy in the same loop. Next-state signals encode two forms of information: *evaluative signals*, which indicate how well the action performed and are extracted as scalar rewards via a PRM judge; and *directive signals*, which indicate how the action should have been different and are recovered through **Hindsight-Guided On-Policy Distillation (OPD)**. We extract textual hints from the next state, construct an enhanced teacher context, and provide token-level directional advantage supervision that is richer than any scalar reward. Due to the asynchronous design, the model serves live requests, the PRM judges ongoing interactions, and the trainer updates the policy at the same time, with zero coordination overhead between them. Applied to **personal agents**, OpenClaw-RL enables an agent to improve simply by being used, recovering conversational signals from user re-queries, corrections, and explicit feedback. Applied to **general agents**, the same infrastructure supports scalable RL across terminal, GUI, SWE, and tool-call settings, where we additionally demonstrate the utility of process rewards.




Figure 1 | **OpenClaw-RL infrastructure overview.** Interaction streams come from two agent types: *Personal Agents* (conversational, single-user), hosted on personal devices, and *General Agents* (terminal, GUI, SWE, and tool-call agents), hosted on cloud services. The collected samples flow into our RL server built on the asynchronous **slime** framework, which consists of four *decoupled components*: (1) the environment server, (2) **PRM/Judge** for reward computation, (3) **Megatron** for policy training, and (4) **SGLang** for policy serving. These components support graceful weight updates and enable training with **any** agentic framework. The environment for personal agents is simply the users' personal devices, which connect to the RL server over HTTP with confidential API keys. The environments for general agents are hosted on cloud services to enable scalable parallelization.



OpenClaw

THE AI THAT ACTUALLY DOES THINGS.

인공 지능 산업 솔루션 ▾ 소프트웨어 ▾ 제품 ▾ 리소스 ▾

NVIDIA NemoClaw

단일 명령으로 더 안전하고 항상 작동하는 AI 어시스턴트를 배포하세요.

GitHub 보기

지금 체험하기



개요 설치 특징 커뮤니티

시작하기